



K-means: Studi Kasus Segmentasi Pelanggan Mall

```
In [ ]: import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
from sklearn.preprocessing import StandardScaler, LabelEncoder
df = pd.read_csv('Mall_Customers.csv')
df.head(10)
```

```
Out[ ]:   CustomerID  Gender  Age  Annual Income (k$)  Spending Score (1-100)
0           1    Male   19              15              39
1           2    Male   21              15              81
2           3  Female   20              16               6
3           4  Female   23              16              77
4           5  Female   31              17              40
5           6  Female   22              17              76
6           7  Female   35              18               6
7           8  Female   23              18              94
8           9    Male   64              19               3
9          10  Female   30              19              72
```

1. Data Preprocessing

Dataset ini terdiri atas 5 kolom, dimana kolom pertama berupa CustomerID sebagai penanda pelanggan, Gender yaitu jenis kelamin pelanggan, Age yaitu umur pelanggan, Annual Income (k\$) yaitu pendapatan pertahun, dan Spending Score (1-100) yaitu nilai yang diberikan oleh mall kepada pelanggan sebagai penilaian seberapa besar seseorang mengeluarkan uang di mall.

```
In [ ]: #Missing values
print("missing value :")
print(df.isna().sum())
#Cek Duplikasi Data
print("jumlah duplikasi = ", df.duplicated().sum())
```

```

missing value :
CustomerID      0
Gender          0
Age            0
Annual Income (k$)  0
Spending Score (1-100)  0
dtype: int64
jumlah duplikasi = 0

```

In []: `df.info()`

```

<class 'pandas.core.frame.DataFrame'>
RangeIndex: 200 entries, 0 to 199
Data columns (total 5 columns):
#   Column                                Non-Null Count  Dtype
---  -
0   CustomerID                            200 non-null    int64
1   Gender                                200 non-null    object
2   Age                                    200 non-null    int64
3   Annual Income (k$)                    200 non-null    int64
4   Spending Score (1-100)                 200 non-null    int64
dtypes: int64(4), object(1)
memory usage: 7.9+ KB

```

Customer ID berisi ID pelanggan dan tidak ada relasi dengan kelompok pelanggan. Oleh karena itu kita tidak membutuhkan kolom CustomerID.

Selanjutnya, pada kolom Gender terdapat dua nilai yakni Male dan Female, maka kita akan menggunakan LabelEncoder untuk merubah Female menjadi value 0 dan Male menjadi value 1.

LabelEncoder sendiri bekerja dengan cara merubah seluruh kategori yang ada di dalam suatu kolom menjadi angka. Angka tersebut diurutkan berdasarkan huruf abjad dari kategori yang ada.

```

In [ ]: #menghapus feature CustomerID
df.drop('CustomerID', axis = 1, inplace = True)
#rename kolom
df.rename(columns = {'Annual Income (k$)': 'Annual Income'}, inplace = True)
df.rename(columns = {'Spending Score (1-100)': 'Spending Score'}, inplace = True)

#merubah nilai male dan female menjadi numeric
from sklearn.preprocessing import StandardScaler, LabelEncoder
labeler = LabelEncoder()
df['Gender'] = labeler.fit_transform(df['Gender'])
df


```

Out[]:

	Gender	Age	Annual Income	Spending Score
0	1	19	15	39
1	1	21	15	81
2	0	20	16	6
3	0	23	16	77
4	0	31	17	40
...	...	...	...	...
195	0	35	120	79
196	0	45	126	28
197	1	32	126	74
198	1	32	137	18
199	1	30	137	83


200 rows × 4 columns

```
In [ ]: sns.pairplot(df, corner=True, diag_kind="kde")  
plt.show()
```




Hal menarik yang dapat kita lihat dari data dan visualisasi data di atas adalah:

- Pengunjung Mall lebih banyak perempuan/female berjumlah 112 sedangkan laki-laki berjumlah



- Rentang umur pengunjung dari 18 sampai 70 tahun, namun sebagian besar pelanggan Mall dengan rentang umur yang lebih muda



- Sebagian besar pelanggan mall memiliki pendapatan dibawah 100K\$
- Terdapat Normal distribusi untuk Spending Score pelanggan, yaitu mendekati nilai 50

```
In [ ]: df.describe()
```

Out[]:

	Gender	Age	Annual Income	Spending Score
count	200.000000	200.000000	200.000000	200.000000
mean	0.440000	38.850000	60.560000	50.200000
std	0.497633	13.969007	26.264721	25.823522
min	0.000000	18.000000	15.000000	1.000000
25%	0.000000	28.750000	41.500000	34.750000
50%	0.000000	36.000000	61.500000	50.000000
75%	1.000000	49.000000	78.000000	73.000000
max	1.000000	70.000000	137.000000	99.000000

Karena jarak data beragam, maka kita akan melakukan **normalisasi** terhadap data **menggunakan Z-score** sehingga data memiliki mean 0 dan standard deviation 1. Semua kolom akan dinormalisasi kecuali Gender.

```
In [ ]: #Scaling Data
scaler = StandardScaler()
# scaling kecuali gender
Gender = df['Gender']
df.drop('Gender', axis = 1)
#proses scaling
df = pd.DataFrame(scaler.fit_transform(df), columns = df.columns)
df['Gender'] = Gender
df.head(5)
```

Out[]:

	Gender	Age	Annual Income	Spending Score
0	1	-1.424569	-1.738999	-0.434801
1	1	-1.281035	-1.738999	1.195704
2	0	-1.352802	-1.700830	-1.715913
3	0	-1.137502	-1.700830	1.040418
4	0	-0.563369	-1.662660	-0.395980

2. Training Model

Sebelum memulai pelatihan berarti kita harus menentukan jumlah kluster. Namun, pada kasus ini kita tidak mengetahuinya oleh karena itu kita dapat menggunakan **elbow method**.


```
In [ ]: from sklearn.cluster import KMeans
inertia_list = []
```

```

for i in range(1,11):
    kmeans = KMeans(n_clusters=i, random_state= 42, n_init=10)
    kmeans.fit(df)
    inertia_list.append(kmeans.inertia_)

plt.figure(figsize = (9,6))
plt.plot(range(1,11), inertia_list, color = 'blue',
         linestyle = 'dashed', marker = 'o',
         markerfacecolor = 'red', markersize = 10)
plt.title('Inertia vs K Value')
plt.xlabel(range(1,11,1))
plt.ylabel('K')
plt.show('Inertia')

```



```

In [ ]: from matplotlib.pyplot import figure, show
import seaborn as sns

plt.figure(figsize=(8,6))
ax = sns.countplot(x=df['Gender'], hue="Gender", data=df, palette="husl",
ax.set_xticks([0, 1])
ax.set_xticklabels(["Female", "Male"])


female, male = df["Gender"].value_counts().values
print("Female: ", female)
print("Male: ", male)

```

```
plt.show()
```

Female: 112

Male: 88




Inertia adalah total jarak dari suatu centroid kepada data yang berada di kluster yang sama.

```
In [ ]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(10,6))
ax = sns.histplot(df["Annual Income"], bins=20, kde=True, color="skyblue")
ax.set_xlabel("Annual Income ($)")
ax.set_ylabel("Jumlah")
ax.set_title("Histogram Annual Income")

plt.show()
```


```
In [ ]: import matplotlib.pyplot as plt
import seaborn as sns

plt.figure(figsize=(10,6))

sns.scatterplot(x=df["Annual Income"], y=df["Spending Score"], s=100, edge

plt.xlabel("Annual Income ($)")
plt.ylabel("Spending Score")
plt.title("Hubungan antara Annual Income dengan Spending Score")

plt.show()
```




In []:

```
In [ ]: km = KMeans(n_clusters=5).fit(df)
# Membaca kembali data asli ke variabel lain
# karena data untuk klustering telah diubah
df_ori = pd.read_csv("Mall_Customers.csv")
df_ori.drop('CustomerID', axis=1, inplace=True)
df_ori.rename(columns={'Annual Income (k$)': 'Annual Income', 'Spending Score (1-100)': 'Spending Score'})

# Membuat satu kolom kategori untuk menampung hasil kluster kita
df_ori['Category'] = km.labels_
sns.pairplot(data=df_ori, hue='Category', palette='rainbow')
```

Out[]: <seaborn.axisgrid.PairGrid at 0x7f9db2388550>




```
In [ ]: from sklearn.metrics import silhouette_score
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

silhouette_scores = []

for k in range(2, 11):
    kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
    labels = kmeans.fit_predict(df[['Annual Income', 'Spending Score']])
    silhouette_scores.append(silhouette_score(df[['Annual Income', 'Spending Score']], labels))

# Plot Silhouette Score
plt.figure(figsize=(8,5))
plt.plot(range(2, 11), silhouette_scores, marker='o', linestyle='--')
plt.xlabel("Number of Clusters")
plt.ylabel("Silhouette Score")
plt.title("Silhouette Score for Optimal K")
```

```
plt.show()
```




```
In [ ]: from sklearn.cluster import KMeans
        from sklearn.metrics import davies_bouldin_score
        import matplotlib.pyplot as plt

        dbi_scores = []
        K_range = range(2, 11) # Minimal 2 Kluster

        for k in K_range:
            kmeans = KMeans(n_clusters=k, random_state=42, n_init=10)
            labels = kmeans.fit_predict(df[['Annual Income', 'Spending Score']])
            dbi = davies_bouldin_score(df[['Annual Income', 'Spending Score']], labels)
            dbi_scores.append(dbi)

        # Plot Davies-Bouldin Index
        plt.figure(figsize=(8,5))
        plt.plot(K_range, dbi_scores, marker='o', linestyle='--')
        plt.xlabel("Number of Clusters")
        plt.ylabel("Davies-Bouldin Index")
        plt.title("Davies-Bouldin Index for Optimal K")
        plt.show()
```




```
In [ ]: import matplotlib.pyplot as plt
import seaborn as sns

fig, axes = plt.subplots(1, 3, figsize=(20, 5))

sns.violinplot(x='Category', y='Age', data=df_ori, ax=axes[0], hue='Category')
sns.violinplot(x='Category', y='Annual Income', data=df_ori, ax=axes[1],
sns.violinplot(x='Category', y='Spending Score', data=df_ori, ax=axes[2],

plt.show()
```



```
In [ ]: df_ori[['Age', 'Annual Income', 'Spending Score', 'Category']].groupby('C
```

Out[]:

	Age	Annual Income	Spending Score
Category			
0	55.551724	48.482759	41.775862
1	25.272727	25.727273	79.363636
2	41.264706	88.500000	16.764706
3	27.957447	50.000000	44.638298
4	32.692308	86.538462	82.128205


Dengan melihat plot diatas, kita dapat memberikan kesimpulan dari pembagian data kita sebagai berikut:

- **Kelompok 1 (Category=0)** Memiliki rata-rata umur 37 tahun, dengan rata-rata annual income \$91 K dan spending score 40.

```
In [ ]: group_1 = df_ori[df_ori['Category'] == 0]
group_1.head()

fig, axes = plt.subplots(1, 3, figsize=(15, 5))

sns.violinplot(x='Gender', y='Age', data=group_1, ax=axes[0])
sns.violinplot(x='Gender', y='Annual Income', data = group_1, ax=axes[1])
sns.violinplot(x='Gender', y='Spending Score', data=group_1, ax=axes[2])
plt.show()
```



Dapat dikatakan kelompok ini dikatakan memiliki kelompok pria dan wanita paruh baya yang memiliki annual income yang tinggi dan spending yang rendah.


- **Kelompok 2 (Category=1)** Kelompok ini memiliki rata-rata umur 55 tahun

dengan kelamin perempuan. Ratarata annual income dan spending score adalah \$52K dan 36.

```
In [ ]: group_2 = df_ori[df_ori['Category'] == 1]

fig, axes = plt.subplots(1, 3, figsize=(15, 5))

sns.violinplot(x='Gender', y='Age', data=group_2, ax=axes[0])
sns.violinplot(x='Gender', y='Annual Income', data=group_2, ax=axes[1])
sns.violinplot(x='Gender', y='Spending Score', data=group_2, ax=axes[2])
plt.show()
```




Kelompok ini adalah kelompok pria paruh baya yang memiliki pendapatan medium dengan spending medium

- Kelompok 3 (Category=2)

```
In [ ]: group_3 = df_ori[df_ori['Category'] == 2]

fig, axes = plt.subplots(1, 3, figsize=(15, 5))


sns.violinplot(x='Gender', y='Age', data=group_3, ax=axes[0])
sns.violinplot(x='Gender', y='Annual Income', data=group_3, ax=axes[1])
sns.violinplot(x='Gender', y='Spending Score', data=group_3, ax=axes[2])
plt.show()
```



Kelompok ini adalah kelompok wanita dengan pendapatan menengah ke bawah namun memiliki spending rendah.

```
In [ ]: df.drop('Gender', axis = 1)
km = KMeans(n_clusters=5).fit(df)
#Membaca kembali original data ke variable lain
mall_ori = pd.read_csv('Mall_Customers.csv')
mall_ori.drop('CustomerID', axis = 1, inplace = True)
mall_ori['Gender'] = labeler.fit_transform(mall_ori['Gender'])
#Membuat stau kolom category untuk menampung hasil kluster kita
mall_ori['Category'] = km.labels_
sns.pairplot(data = mall_ori, hue = 'Category', palette = 'rainbow')
```

```
Out[ ]: <seaborn.axisgrid.PairGrid at 0x7f9dbcb60550>
```

Sekarang, kita dapat mengambil kesimpulan dari hasil kluster di atas tanpa gender sebagai berikut:

- Kelompok 0 merepresentasikan pelanggan dengan annual income sangat rendah, spending score rendah, dan rentang umur yang beragam
- Kelompok 1 merepresentasikan pelanggan dengan annual income agak rendah, spending score agak rendah, dan memiliki rentang umur menengah hingga tua
- Kelompok 2 merepresentasikan pelanggan dengan rentang umur menengah ke arah muda, annual income menengah hingga tinggi, serta spending score yang tinggi
- Kelompok 3 merepresentasikan pelanggan dengan rentang umur muda,

annual income yang rendah, serta spending score yang menengah hingga tinggi

- Kelompok 4 merepresentasikan pelanggan dengan umur yang beragam, annual income menengah hingga tinggi, serta spending score yang rendah

Dengan merubah data yang dilatih, kita mampu mendapatkan perspektif baru. Selain itu, dengan merubah nilai K juga, kita dapat melihat kelompok baru yang belum dapat kita lihat