

M 3 Clustering: Segmentasi Pelanggan pada Dataset USArrests

Teknik Penambangan Data

Denty Nirwana Bintang - J0403221036

2024-11-25

Daftar Isi

1	Pendahuluan	2
2	Eskplorasi Data Awal (EDA)	3
2.1	Analisis Statistik Deskriptif	3
2.2	Visualisasi Distribusi Data	3
2.3	Deteksi Outlier	5
3	Standarisasi Data	6
4	Clustering Menggunakan K-means	7
4.1	Pemilihan Jumlah Kluster Optimal (Metode Elbow)	7
4.2	Implementasi K-means	8
5	Visualisasi dan Interpretasi	8
5.1	Visualisasi Hasil Clustering	8
5.2	Interpretasi Kluster	10
6	Kesimpulan	10

1 Pendahuluan

Analisis data telah menjadi alat penting dalam memahami pola dan karakteristik tertentu, termasuk tingkat kriminalitas di berbagai wilayah. Dalam studi ini, digunakan dataset USArrests, yang memuat data kriminalitas di negara bagian Amerika Serikat berdasarkan empat kategori: pembunuhan (Murder), penyerangan (Assault), kepadatan penduduk urban (UrbanPop), dan kejahatan seksual (Rape). Melalui metode K-means clustering, negara bagian akan dikelompokkan ke dalam klaster yang memiliki karakteristik serupa, membantu mengidentifikasi pola kriminalitas yang unik di masing-masing wilayah.

Proses analisis mencakup eksplorasi data awal (Exploratory Data Analysis), yang bertujuan memahami distribusi data, mendeteksi outlier, dan mengidentifikasi pola awal. Setelah itu, data distandarisasi agar variabel dengan skala besar tidak mendominasi proses clustering. Penentuan jumlah klaster optimal dilakukan menggunakan metode Elbow dan Silhouette Score. Visualisasi hasil clustering memberikan gambaran tentang distribusi klaster, sementara interpretasi mendalam terhadap hasilnya diharapkan dapat memberikan wawasan tentang pola kriminalitas di Amerika Serikat, yang relevan untuk dasar pengambilan kebijakan keamanan.

2 Eksplorasi Data Awal (EDA)

2.1 Analisis Statistik Deskriptif

```
# Load dataset
data("USArrests")
```

```
# Melihat struktur data
str(USArrests)
```

```
'data.frame':  50 obs. of  4 variables:
 $ Murder   : num  13.2 10 8.1 8.8 9 7.9 3.3 5.9 15.4 17.4 ...
 $ Assault  : int  236 263 294 190 276 204 110 238 335 211 ...
 $ UrbanPop : int  58 48 80 50 91 78 77 72 80 60 ...
 $ Rape     : num  21.2 44.5 31 19.5 40.6 38.7 11.1 15.8 31.9 25.8 ...
```

```
# Descriptive statistics
summary(USArrests)
```

Murder	Assault	UrbanPop	Rape
Min. : 0.800	Min. : 45.0	Min. :32.00	Min. : 7.30
1st Qu.: 4.075	1st Qu.:109.0	1st Qu.:54.50	1st Qu.:15.07
Median : 7.250	Median :159.0	Median :66.00	Median :20.10
Mean : 7.788	Mean :170.8	Mean :65.54	Mean :21.23
3rd Qu.:11.250	3rd Qu.:249.0	3rd Qu.:77.75	3rd Qu.:26.18
Max. :17.400	Max. :337.0	Max. :91.00	Max. :46.00


Penjelasan Parameter Format:

- data("USArrests"): Memuat dataset bawaan R yang berisi tingkat kejahatan dari negara bagian di AS.
- str(USArrests): Menampilkan struktur dataset, termasuk jumlah observasi, kolom, dan tipe data.
- summary(USArrests): Memberikan statistik deskriptif (mean, median, quartile) untuk tiap variabel.


Dataset USArrests memiliki 50 observasi (negara bagian) dan 4 variabel: Murder, Assault, UrbanPop, dan Rape. Dari analisis statistik, terlihat bahwa rata-rata tingkat pembunuhan (Murder) adalah sekitar 7.8 per 100.000 orang, dengan rentang dari 0.8 hingga 17.4. Variabel Assault menunjukkan variasi yang besar dengan nilai maksimum mencapai 337. Sementara itu, UrbanPop (persentase populasi urban) memiliki median di sekitar 66%, menunjukkan distribusi yang cukup merata.

2.2 Visualisasi Distribusi Data

```
# Pair plot untuk distribusi antar variabel
pairs(USArrests, main = "Distribusi Data USArrests")
```



```
# Histogram setiap variabel
par(mfrow = c(2, 2))
hist(USArrests$Murder,
     main = "Distribusi Murder", xlab = "Murder", col = "orange", border = "black")
hist(USArrests$Assault,
     main = "Distribusi Assault", xlab = "Assault", col = "orange", border = "black")
hist(USArrests$UrbanPop,
     main = "Distribusi UrbanPop", xlab = "UrbanPop", col = "orange", border = "black")
hist(USArrests$Rape,
     main = "Distribusi Rape", xlab = "Rape", col = "orange", border = "black")
```




Penjelasan :

- `pairs(USArrests)`: Membuat scatterplot matrix untuk melihat hubungan antar variabel.
- `par(mfrow = c(2, 2))`: Membagi area plotting menjadi grid 2x2, sehingga empat histogram dapat ditampilkan secara bersamaan dalam satu layar.
- `hist(USArrests$...)`: Membuat histogram.

Visualisasi pair plot menunjukkan hubungan positif antara Murder dan Assault, serta Rape. Artinya, negara bagian dengan tingkat pembunuhan tinggi cenderung memiliki tingkat penyerangan dan pemerkosaan yang tinggi juga. Histogram setiap variabel mengungkapkan bahwa Murder dan Rape cenderung memiliki distribusi yang miring ke kanan (positively skewed), sedangkan UrbanPop menunjukkan distribusi yang lebih seragam.

2.3 Deteksi Outlier

```
# Boxplot untuk mendeteksi outlier
boxplot(USArrests, main = "Boxplot Data USArrests", col = c("red", "blue", "green", "yellow"))
```



Penjelasan :

- boxplot: Membuat visualisasi kotak untuk mendeteksi outlier di setiap variabel.
- col: Memberikan warna berbeda pada setiap kotak untuk kejelasan.

Boxplot menunjukkan bahwa variabel Murder, Assault, dan Rape memiliki beberapa outlier, misalnya negara bagian dengan tingkat pembunuhan atau pemerkosaan yang jauh lebih tinggi dibanding rata-rata. Ini menunjukkan adanya variasi ekstrem dalam dataset yang perlu diperhatikan saat melakukan analisis clustering.

3 Standarisasi Data

```
# Standarisasi data
scaled_data <- scale(USArrests)
head(scaled_data)
```

	Murder	Assault	UrbanPop	Rape
Alabama	1.24256408	0.7828393	-0.5209066	-0.003416473
Alaska	0.50786248	1.1068225	-1.2117642	2.484202941
Arizona	0.07163341	1.4788032	0.9989801	1.042878388

Arkansas	0.23234938	0.2308680	-1.0735927	-0.184916602
California	0.27826823	1.2628144	1.7589234	2.067820292
Colorado	0.02571456	0.3988593	0.8608085	1.864967207

Penjelasan :


- scale: Menstandarisasi data sehingga setiap variabel memiliki rata-rata 0 dan standar deviasi 1.
- head(scaled_data): Menampilkan data yang telah distandarisasi.

Standarisasi mengubah semua variabel menjadi skala dengan rata-rata 0 dan deviasi standar 1, memastikan tidak ada variabel yang mendominasi proses clustering.

4 Clustering Menggunakan K-means

4.1 Pemilihan Jumlah Kluster Optimal (Metode Elbow)

```
set.seed(123)
wss <- sapply(1:10, function(k) { kmeans(scaled_data, centers = k, nstart = 20)$tot.withinss })
plot(1:10, wss, type = "b", pch = 19, frame = FALSE,
     xlab = "Jumlah Kluster", ylab = "Total Within Sum of Squares")
```



Penjelasan :

- kmeans: Menjalankan algoritma K-means untuk berbagai jumlah klaster.
- sapply: Menghitung total within-cluster sum of squares (WSS) untuk setiap nilai k.
- plot: Membuat grafik WSS terhadap jumlah klaster.

Grafik Elbow menunjukkan bahwa WSS menurun signifikan hingga sekitar 3–4 klaster, kemudian perlambatan terjadi. Ini menunjukkan bahwa jumlah klaster optimal kemungkinan berada pada 3 atau 4.

4.2 Implementasi K-means

```
# Menentukan klaster berdasarkan jumlah optimal
final_kmeans <- kmeans(scaled_data, centers = 4, nstart = 20)

# Menambahkan hasil klaster ke data
USArrests$Cluster <- as.factor(final_kmeans$cluster)
head(USArrests)
```

	Murder	Assault	UrbanPop	Rape	Cluster
Alabama	13.2	236	58	21.2	1
Alaska	10.0	263	48	44.5	3
Arizona	8.1	294	80	31.0	3
Arkansas	8.8	190	50	19.5	1
California	9.0	276	91	40.6	3
Colorado	7.9	204	78	38.7	3

Penjelasan :

- centers = 4: Menggunakan 4 klaster berdasarkan hasil Elbow.
- nstart = 20: Memastikan inisialisasi yang optimal dengan menjalankan algoritma beberapa kali.
- as.factor: Menambahkan hasil klaster sebagai variabel baru dalam dataset.

K-means berhasil membagi negara bagian menjadi 4 klaster. Setiap klaster merepresentasikan kelompok negara bagian dengan karakteristik tingkat kejahatan yang serupa. Negara bagian dalam klaster tertentu memiliki tingkat pembunuhan, penyerangan, atau populasi urban yang mendominasi.

5 Visualisasi dan Interpretasi

5.1 Visualisasi Hasil Clustering



```
library(factoextra)
```

Warning: package 'factoextra' was built under R version 4.3.3

Loading required package: ggplot2

Welcome! Want to learn more? See two factoextra-related books at <https://goo.gl/ve3WBa>

```
fviz_cluster(final_kmeans, data = scaled_data) + ggtitle("Visualisasi Kluster dengan PCA")
```



Penjelasan :

- library(factoextra): Memuat library untuk visualisasi kluster.
- fviz_cluster: Memvisualisasikan hasil k-means menggunakan data terstandardisasi.
- – ggtitle: Menambahkan judul “Visualisasi Kluster dengan PCA”.

Plot PCA menunjukkan bahwa negara bagian terbagi dalam empat kluster dengan distribusi yang relatif terpisah. Misalnya, kluster dengan tingkat Murder dan Assault tinggi berbeda signifikan dari kluster dengan tingkat kejahatan rendah.

5.2 Interpretasi Klaster

```
aggregate(USArrests[, 1:4], by = list(Cluster = USArrests$Cluster), mean)
```

	Cluster	Murder	Assault	UrbanPop	Rape
1	1	13.93750	243.62500	53.75000	21.41250
2	2	3.60000	78.53846	52.07692	12.17692
3	3	10.81538	257.38462	76.00000	33.19231
4	4	5.65625	138.87500	73.87500	18.78125

Penjelasan :

- aggregate: Menghitung rata-rata tiap variabel dalam klaster untuk interpretasi.
- by = list(Cluster = USArrests\$Cluster): Mengelompokkan data berdasarkan klaster.

Berdasarkan visualisasi klaster dengan PCA, negara bagian di Amerika Serikat dapat dikelompokkan ke dalam empat klaster utama berdasarkan karakteristik tingkat kejahatan (Murder, Assault, UrbanPop, dan Rape). Klaster 1 mencakup negara bagian dengan pola kejahatan yang homogen, Klaster 2 terdiri dari negara bagian dengan tingkat kejahatan relatif rendah, Klaster 3 mencakup negara bagian dengan variasi tingkat kejahatan yang lebih tinggi, sedangkan Klaster 4 mencakup negara bagian dengan pola kejahatan moderat. Dimensi 1 dan Dimensi 2 menjelaskan 62% dan 24.7% variansi data, menunjukkan perbedaan signifikan antar klaster. Pola ini dapat digunakan untuk memahami distribusi tingkat kejahatan dan menyusun kebijakan keamanan yang lebih terfokus.

6 Kesimpulan

Kesimpulan dari hasil analisis ini adalah bahwa dengan menggunakan metode K-means clustering pada dataset USArrests, negara bagian di Amerika Serikat dapat dikelompokkan ke dalam empat klaster yang menunjukkan pola tingkat kejahatan yang berbeda. Hasil clustering ini menggambarkan:

- Klaster 1: Negara bagian dengan tingkat kejahatan yang sangat tinggi (terutama pembunuhan dan penyerangan).
- Klaster 2: Negara bagian dengan tingkat kejahatan yang relatif rendah secara keseluruhan.
- Klaster 3: Negara bagian dengan tingkat kejahatan yang cukup tinggi, terutama dalam hal penyerangan dan pemerkosaan.
- Klaster 4: Negara bagian dengan tingkat kejahatan moderat, dengan variasi yang lebih rendah dibandingkan klaster lainnya.

Pola-pola ini memberikan wawasan penting mengenai distribusi kejahatan di berbagai wilayah, yang dapat digunakan untuk merumuskan kebijakan keamanan dan intervensi yang lebih tepat dan efisien sesuai dengan karakteristik masing-masing klaster. Dengan demikian, analisis ini dapat membantu pihak berwenang dalam merancang kebijakan yang lebih sesuai dengan kebutuhan spesifik setiap wilayah.